# ДЗ-05-Entity-Resolution

# ДЗ-05: Entity Resolution та зв'язки — від сутностей до графа

**Урок:** Урок-05-Entity-Resolution
**Час виконання:** 1–2 години
**Дедлайн:** до наступного заняття

---

## 🔵 Базовий рівень (обов'язкове) — ~1 година

> Не потребує встановлення жодних інструментів. Виконується у браузері.

### Мета

1. Зрозуміти entity resolution на практиці — знайти різні записи про одну й ту саму людину
2. Навчитися будувати граф зв'язків вручну
3. Застосувати шкалу впевненості (1–10) до реальних знахідок
4. Виконати Collision Detection — переконатися, що ви досліджуєте правильну людину

---

### Що потрібно зробити

#### Завдання 1 — Таблиця ідентифікаторів

Оберіть будь-яку **публічну особу** — підприємець, журналіст, місцевий політик, громадський активіст. Тільки публічна діяльність, тільки відкриті джерела.

Знайдіть **мінімум 5 різних записів** про цю людину в різних джерелах. Для кожного запишіть:

| Ідентифікатор | Значення | Джерело | Впевненість (1–10) |
|---|---|---|---|
| Повне ім'я | | LinkedIn / ЗМІ / реєстр | |
| Email | | Витік / публічний профіль | |
| Телефон | | Публічний сайт / реєстр | |
| Нікнейм | | GitHub / Telegram / Twitter | |
| Компанія | | ЄДРПОУ / LinkedIn | |
| Адреса | | Реєстр / сайт компанії | |

> **Що тут важливо зрозуміти:** один і той самий запис може мати різну оцінку впевненості залежно від джерела. Email із витоку бази даних — 7/10. Email, підтверджений LinkedIn і реєстром — 10/10.

---

## Завдання 2 — Граф зв'язків у draw.io

Побудуйте граф у draw.io (безкоштовно, у браузері, без реєстрації):

- **Мінімум 6 вузлів** (особа, компанії, адреси, акаунти, події — будь-які сутності)
- **Мінімум 8 ребер** з підписом типу зв'язку (CEO, засновник, адреса, email, знайомий тощо)
- На кожному ребрі — оцінка впевненості (1–10)

**Колірне кодування вузлів (рекомендовано):**

- Синій — особа
- Жовтий — організація
- Зелений — локація
- Червоний — артефакт (email, IP, домен, телефон)

> **Що тут важливо зрозуміти:** граф — це не просто малюнок. Кожне ребро — це перевірений факт з джерелом. Якщо джерела немає — ребро не малюється.

---

## Завдання 3 — Collision Detection

Перевірте: чи є хтось інший з таким самим іменем у публічних джерелах?

Дайте відповіді на 3 питання:

1. Скільки людей з таким іменем знайшлося у відкритих джерелах?
2. Які 2 факти однозначно ідентифікують саме вашу людину (а не однофамільця)?
3. Чи є хоча б один зв'язок у вашому графі, який ви б **не** включили через ризик collision? Чому?

> **Що тут важливо зрозуміти:** collision — найпоширеніша помилка OSINT-аналітика. Перевірити альтернативну гіпотезу ("це інша людина") так само важливо, як знайти зв'язок.

---

## Формат виконання

- Таблиця ідентифікаторів — Markdown або Google Sheets (посилання)

- Граф — скріншот із draw.io (PNG або PDF)
- Відповіді на Collision Detection — 5–10 речень вільного тексту

---

## Що саме потрібно здати

1. Таблиця ідентифікаторів (мінімум 5 рядків, заповнені всі колонки)
2. Скріншот графу (мінімум 6 вузлів, 8 ребер, підписані ребра)
3. Відповіді на 3 питання Collision Detection

---

## Acceptance Criteria 🔵

- [ ] Таблиця містить мінімум 5 ідентифікаторів з різних джерел
- [ ] Кожен ідентифікатор має оцінку впевненості 1–10 і назву джерела
- [ ] Граф має мінімум 6 вузлів і 8 ребер
- [ ] Кожне ребро підписане (тип зв'язку + впевненість)
- [ ] Collision Detection — наявні відповіді на всі 3 питання
- [ ] Досліджувана особа — публічна, всі дані з відкритих джерел

---

# 🔴 Просунутий рівень (бажане) — +30–40 хвилин

> Потребує встановленого Docker. Якщо Docker не запускається — просунутий рівень не обов'язковий.

## Мета

1. Встановити Flowsint і запустити перше автоматичне розслідування
2. Порівняти ручний граф (Базовий рівень) з автоматично побудованим
3. Зрозуміти, що автоматизація доповнює, а не замінює аналітика

---

## Що потрібно зробити

### Встановлення Flowsint

```
git clone https://github.com/reconurge/flowsint.git
cd flowsint
make prod
```

Відкрийте http://localhost:5173/register і створіть обліковий запис.

> Встановлення займає 15–20 хвилин (Docker завантажує образи). Запустіть заздалегідь.

---

### Завдання 4 — Flowsint: автоматичне розслідування

Використайте **той самий суб'єкт**, що досліджували у Базовому рівні.

1. Додайте домен його компанії або email як сутність у Flowsint
2. Запустіть усі доступні збагачувачі для цієї сутності
3. Слідуйте мінімум за **2 новими вузлами**, що з'явилися (наприклад: домен → IP → ASN)
4. Зробіть скріншот фінального графу

> **Що тут важливо зрозуміти:** Flowsint будує граф автоматично, але ви вирішуєте, які ребра заслуговують на довіру. Інструмент — помічник, не суддя.

---

### Завдання 5 — Порівняльний аналіз

Напишіть 5–8 речень:

- Що Flowsint знайшов, чого **не було** у вашому ручному графі?
- Що знайшли ви руками, чого Flowsint **не показав**?
- Яка оцінка впевненості у нових автоматичних знахідок? Чому?

---

## Формат виконання

- Скріншот графу Flowsint
- Порівняльний аналіз — 5–8 речень вільного тексту

---

## Що саме потрібно здати

1. Скріншот графу Flowsint (з мінімум 8 вузлами після збагачення)
2. Порівняльний аналіз (ручний граф vs Flowsint)

---

## Acceptance Criteria 🔴

- [ ] Flowsint встановлений і запущений
- [ ] Досліджена мінімум 1 сутність з 2+ збагачувачами
- [ ] Граф містить мінімум 8 вузлів після збагачення
- [ ] Порівняльний аналіз містить конкретні знахідки (не загальні слова)
- [ ] Нові автоматичні знахідки оцінені за шкалою впевненості 1–10

---

## Примітка

- Досліджуйте лише **публічних осіб** і лише їх **публічну діяльність**
- Не публікуйте зібрані дані у відкритий доступ
- Якщо при встановленні Flowsint виникла помилка — опишіть її у здачі: це теж корисний досвід
- Оцінка впевненості нижче **5/10** — не включайте до фінального графу або позначайте окремо як «потребує перевірки»

---

← *Урок-05-Entity-Resolution* | *Наступний урок: Урок-06-Теорія-графів* →